ARCHITECTURE MANUAL / 01

# YingluoNet

# 结构说明书

v1.1　从一个神经元到完整前向传播

每一层先生成相位，让相位之间发生一次交互；
再把正弦分支与 Tanh 分支按比例混合，
最后叠加到输入上，形成这一层的输出。




**本书的阅读重点**

先看“数据经过哪些步骤”，再看“每一步为什么这样写”。公式均配有符号解释；正文提供一个可手算的两神经元例子，并在后半部分给出批量计算、参数初始化和梯度传播的对应关系。

核心定义：YingluoLayer v1.1　　文档日期：2026 年 11 月 11 日

数学结构 / 前向传播 / 参数说明 / 接口说明

## 阅读指南

> **先记住一条主线**
>
> **相位生成 → 相位交互 → 双分支混合 → 残差输出。**
> 整张网络，就是在输入与输出之间串联若干个这样的核心层。

初次阅读可以顺着第 1–7 节走，重点看第 7 节的数值例子。需要与程序核对时，再看第 8–10 节；第 11–12 节用于理解训练与结构性质。最后一页可单独用作公式速查。

## 目录


1 先看全貌：输入、核心层、输出 . . . . . 3

2 符号与维度：先分清参数和中间量 . . . . . 4

3 相位生成与相位耦合 . . . . . 5

4 把成对交互改写成矩阵计算 . . . . . 6

5 两条特征分支与一个门控 . . . . . 7

6 残差融合：保留输入，再加入修正 . . . . . 8

7 手算一次：两个神经元的完整例子 . . . . . 9

8 从核心层拼成完整网络 . . . . . 10

9 批量前向传播：与张量维度对应 . . . . . 11

10 参数初始化与参数量 . . . . . 12

11 拓展阅读：梯度怎样穿过核心层 . . . . . 13

12 读公式时的几个关键细节 . . . . . 14

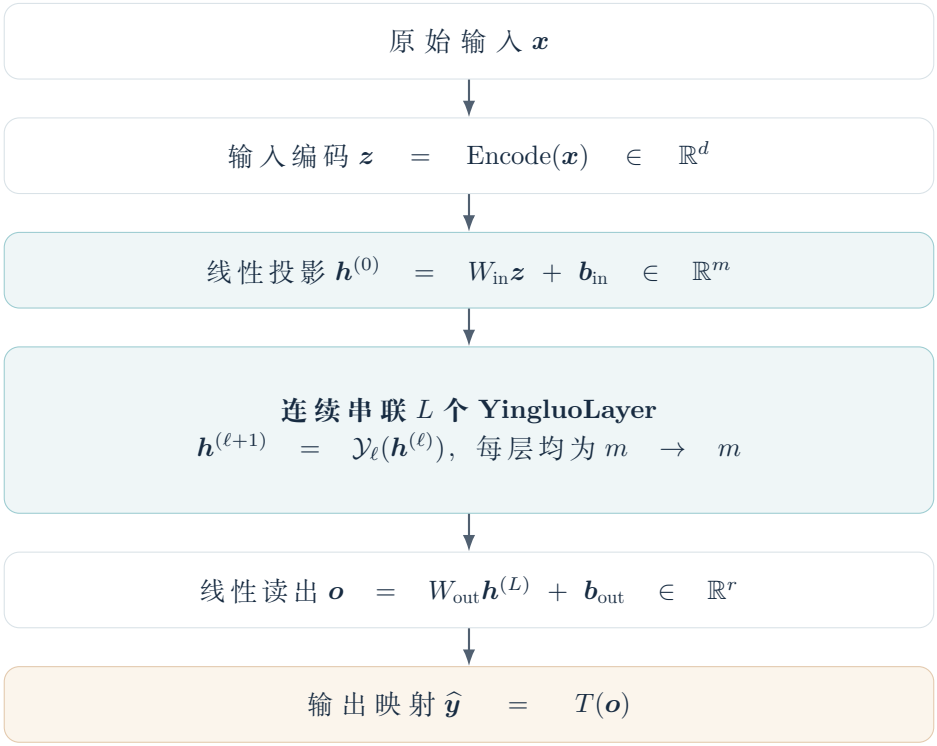
A 一页速查：核心公式与计算顺序 . . . . . 15


**版本口径** 本说明书依据本次对话中确定的 YingluoNet v1.1 公式与前向传播结构整理。核心层采用有向、零对角线耦合和 $1/m$ 缩放。输入编码、输出映射与训练损失分别说明，不混入核心层定义。数值算例为教学构造，不是训练权重。

# 1 先看全貌：输入、核心层、输出

## 1.1 三个部分各自做什么

YingluoNet 可以拆成三个部分：**输入接口**把数据整理成向量；**核心层**反复变换特征；**输出接口**把最终特征读成所需的数值。核心层的名称是 **YingluoLayer**。




## 1.2 核心层保持宽度不变

这里 $d$ 是编码后的输入维度，$m$ 是隐藏宽度，$L$ 是核心层数量，$r$ 是输出维度。每层都接收一个 $m$ 维向量，再输出一个 $m$ 维向量，所以原输入与非线性修正可以直接相加。

> **“结构相同”与“参数相同”是两回事**
>
> 不同层采用相同的计算规则，但分别拥有自己的 $W_p, W_a, W_g, K$、偏置和 $\alpha$。它们不是同一组权重的重复使用。一次前向传播按层顺序计算，参数在这次计算中保持固定。

# 2 符号与维度：先分清参数和中间量

正文先使用**单个样本的列向量**约定。向量用粗体表示，矩阵用大写字母表示；第 9 节再转换到程序常用的“每行一个样本”约定。

## 2.1 这些量随当前输入变化

| 符号 | 维度 | 通俗解释 |
|---|---|---|
| $\boldsymbol{h}$ | $m \times 1$ | 进入当前核心层的特征 |
| $\boldsymbol{\theta}$ | $m \times 1$ | 每个神经元的原始相位 |
| $\boldsymbol{c}$ | $m \times 1$ | 其他相位带来的修正 |
| $\boldsymbol{\psi}$ | $m \times 1$ | 修正后的相位，$\boldsymbol{\psi} = \boldsymbol{\theta} + \boldsymbol{c}$ |
| $\boldsymbol{p}$ | $m \times 1$ | 正弦分支的输出 |
| $\boldsymbol{a}$ | $m \times 1$ | Tanh 分支的输出 |
| $\boldsymbol{g}$ | $m \times 1$ | 两个分支的混合比例 |
| $\boldsymbol{f}$ | $m \times 1$ | 混合后的非线性特征 |
| $\boldsymbol{h}_+$ | $m \times 1$ | 当前核心层的最终输出 |

## 2.2 这些量通过训练调整

| 参数 | 维度 | 作用 |
|---|---|---|
| $W_p, \boldsymbol{b}_p$ | $m \times m,\ m$ | 生成原始相位 |
| $W_a, \boldsymbol{b}_a$ | $m \times m,\ m$ | 生成 Tanh 分支特征 |
| $W_g, \boldsymbol{b}_g$ | $m \times m,\ m$ | 生成门控比例 |
| $K$ | $m \times m$ | 控制相位之间的交互权重 |
| $\alpha$ | 标量 | 控制非线性修正的层级强度 |

## 2.3 三种运算不要混淆

$W\boldsymbol{h}$ 是**矩阵乘法**，会混合不同坐标。$\boldsymbol{u} \odot \boldsymbol{v}$ 是**逐元素乘法**，即 $(\boldsymbol{u} \odot \boldsymbol{v})_i = u_i v_i$。$\sin(\boldsymbol{\theta})$ 等函数也是逐元素计算。

> **最容易混淆的一点**
>
> $W_g$ 和 $\boldsymbol{b}_g$ 是参数；$\boldsymbol{g}$ 是由当前输入算出来的结果。同样，$K$ 是参数，$\boldsymbol{c}$ 是由 $K$ 和当前相位共同算出的结果。$\alpha$ 是每层一个标量，不是每个神经元一个门控。

# 3 相位生成与相位耦合

## 3.1 先给每个神经元一个相位

$$\boxed{\boldsymbol{\theta} = W_p \boldsymbol{h} + \boldsymbol{b}_p}, \qquad \theta_i = \sum_{k=1}^{m} W_{p,ik} h_k + b_{p,i}. \tag{1}$$

这一步仍然是加权求和。“相位”指进入正弦、余弦运算的实数，按弧度解释；它不必是外部测得的物理相位，也不必限制在 $[0, 2\pi)$ 内。

## 3.2 再计算同层神经元的相互修正

$$\boxed{c_i = \frac{1}{m} \sum_{j=1}^{m} K_{ij} \sin(\theta_j - \theta_i)}, \qquad K_{ii} = 0. \tag{2}$$

**读法：**对第 $i$ 个神经元，依次比较其他神经元 $j$ 的相位；把每个相位差变成正弦信号，乘以对应的 $K_{ij}$，求和后除以宽度 $m$。

| 相位差 $\theta_j - \theta_i$ | 正弦值 | 仅看该条连接的交互信号 |
|---|---|---|
| $0$ 或 $\pi$ | $0$ | 这一项为零 |
| $\pi/2$ | $1$ | 等于 $K_{ij}/m$ |
| $-\pi/2$ | $-1$ | 等于 $-K_{ij}/m$ |

**方向约定：**$K_{ij}$ 表示“$j$ 对 $i$ 的影响”。$K_{ij}$ 可以为正或负；$K_{ij}$ 与 $K_{ji}$ 独立，因而是有向耦合。对角线恒为零，因为 $\sin(\theta_i - \theta_i) = 0$。

> **设计目的**
>
> 用相位差显式构造特征之间的交互，而不是只对每个相位独立施加激活。$1/m$ 把交互写成按宽度缩放的加权和；它不代表每项相加后一定保持相同方差。

> **所有神经元同时更新**
>
> 先算出完整的原始相位 $\boldsymbol{\theta}$，再用这同一组相位算全部 $c_i$，最后得到 $\boldsymbol{\psi} = \boldsymbol{\theta} + \boldsymbol{c}$。这里没有“算完第一个就拿新值去算第二个”的顺序更新，也没有层内反复迭代。

# 4 把成对交互改写成矩阵计算

直接为每对神经元构造相位差，会产生一个 $m \times m$ 的中间矩阵。相同的计算可以只使用正弦向量、余弦向量和两次矩阵乘法。

## 4.1 从三角恒等式开始

$$\sin(\theta_j - \theta_i) = \sin\theta_j \cos\theta_i - \cos\theta_j \sin\theta_i.$$

代入式 (2)，把与 $j$ 无关的项提出求和号：

$$c_i = \frac{1}{m}\left[\cos\theta_i \sum_j K_{ij} \sin\theta_j - \sin\theta_i \sum_j K_{ij} \cos\theta_j\right]. \tag{3}$$

定义两个向量

$$\boldsymbol{u} = \sin\boldsymbol{\theta}, \qquad \boldsymbol{v} = \cos\boldsymbol{\theta},$$

于是得到与逐项求和完全相同的公式：

$$\boxed{\boldsymbol{c} = \frac{1}{m}\left[\boldsymbol{v} \odot (K\boldsymbol{u}) - \boldsymbol{u} \odot (K\boldsymbol{v})\right].} \tag{4}$$

## 4.2 实际执行顺序

| 步骤 | 计算 | 得到什么 |
|---|---|---|
| 1 | $\boldsymbol{u} = \sin\boldsymbol{\theta}$ | 全部相位的正弦 |
| 2 | $\boldsymbol{v} = \cos\boldsymbol{\theta}$ | 全部相位的余弦 |
| 3 | $\boldsymbol{r} = K\boldsymbol{u}$ | 正弦特征的加权汇总 |
| 4 | $\boldsymbol{q} = K\boldsymbol{v}$ | 余弦特征的加权汇总 |
| 5 | $\boldsymbol{c} = (\boldsymbol{v} \odot \boldsymbol{r} - \boldsymbol{u} \odot \boldsymbol{q})/m$ | 每个神经元的相位修正 |

**设计目的**

把显式的“逐对比较”改写成规则的张量运算。对一批 $b$ 个样本，主要运算量仍为 $O(bm^2)$，但不必显式保存 $b \times m \times m$ 的相位差张量。加上三条分支投影，每层矩阵运算主体约为 $5bm^2$ 次乘加，另有逐元素函数运算。

**检查方向的简单方法**

若只有 $K_{12}$ 非零，则只有第 1 个神经元得到来自第 2 个神经元的直接相位修正。第 9 节采用行向量批量公式时，矩阵乘法会出现 $K^{\mathsf{T}}$，但方向约定完全不变。

# 5 两条特征分支与一个门控

## 5.1 正弦分支：把修正后的相位读成特征

$$\psi = \boldsymbol{\theta} + \boldsymbol{c}, \qquad \boxed{\boldsymbol{p} = \sin \psi.} \tag{5}$$

这里的 sin 逐元素计算。相位修正发生在正弦函数**里面**，因此是先改相位、再产生输出；不是在正弦输出之后再额外加上 $\boldsymbol{c}$。

## 5.2 Tanh 分支：另一条独立的特征通道

$$\boxed{\boldsymbol{a} = \tanh(W_a \boldsymbol{h} + \boldsymbol{b}_a).} \tag{6}$$

这里 $\tanh z = (e^z - e^{-z})/(e^z + e^{-z})$，提供平滑、饱和的非周期响应。这一支直接读取 $\boldsymbol{h}$，不读取 $\boldsymbol{p}$ 或修正后的相位；它有独立的权重 $W_a$ 和偏置 $\boldsymbol{b}_a$。

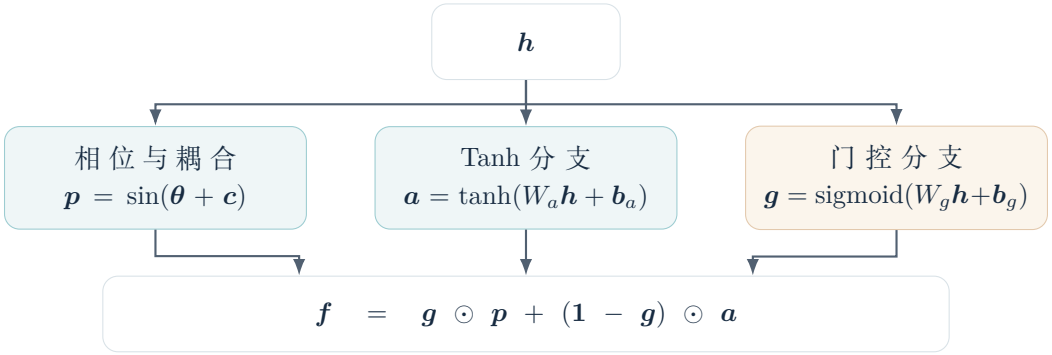
## 5.3 门控：按输入决定混合比例

$$\boxed{\boldsymbol{g} = \mathrm{sigmoid}(W_g \boldsymbol{h} + \boldsymbol{b}_g)}, \qquad \mathrm{sigmoid}(z) = \frac{1}{1 + e^{-z}}. \tag{7}$$

每个 $g_i$ 都在 $(0, 1)$ 之间，然后进行逐元素融合：

$$\boxed{\boldsymbol{f} = \boldsymbol{g} \odot \boldsymbol{p} + (\boldsymbol{1} - \boldsymbol{g}) \odot \boldsymbol{a}.} \tag{8}$$

例如 $p_i = 0.8$、$a_i = 0.2$、$g_i = 0.75$，则 $f_i = 0.75 \times 0.8 + 0.25 \times 0.2 = 0.65$。每个神经元的比例分别计算，而且同一神经元面对不同输入时，比例也可以不同。




**设计目的**

为同一层提供两种非线性响应，再让门控决定如何组合。$g_i$ 是分支的混合系数，不是该分支对最终预测的“贡献百分比”；后面还有残差和其他层。

# 6 残差融合：保留输入，再加入修正

前面的分支计算得到了 $\boldsymbol{f}$，但它还不是当前层的最终输出。YingluoLayer 会把原输入 $\boldsymbol{h}$ 一起保留下来。

$$\boxed{\boldsymbol{h}_{+} = \frac{\boldsymbol{h} + \alpha \boldsymbol{f}}{\sqrt{1+\alpha^2}}.} \tag{9}$$

## 6.1 两条路径怎样叠加

把式 (9) 拆开看：

$$\boldsymbol{h}_{+} = \underbrace{\frac{1}{\sqrt{1+\alpha^2}}}_{\text{输入路径系数}} \boldsymbol{h} + \underbrace{\frac{\alpha}{\sqrt{1+\alpha^2}}}_{\text{修正路径系数}} \boldsymbol{f}.$$

第一项沿着直接路径传递输入；第二项把非线性计算结果加进来。$\alpha$ 是**每层独立的一个可训练实数**，不是按输入生成的向量。

| $\alpha$ | 输入系数 | 修正系数 | 直观含义 |
|---|---|---|---|
| 0 | 1 | 0 | 该层为恒等映射 |
| 0.1 | 约 0.9950 | 约 0.0995 | 从较小的非线性修正开始 |
| 1 | 约 0.7071 | 约 0.7071 | 两条路径使用相同系数 |

## 6.2 分母是尺度控制，不是标准化层

两个路径系数的平方和等于 1，但系数之和通常不等于 1。因此，这不是两个向量的普通加权平均，也不是 LayerNorm 或 BatchNorm。若把某一坐标在样本间的变化看作随机变量，则

$$\operatorname{Var}(h_{+,i}) = \frac{\operatorname{Var}(h_i) + \alpha^2 \operatorname{Var}(f_i) + 2\alpha \operatorname{Cov}(h_i, f_i)}{1+\alpha^2}.$$

由于 $\boldsymbol{f}$ 本来就由 $\boldsymbol{h}$ 算出，两者一般有关联，不能把分母解释成“严格保持方差不变”。

**设计目的**

让输入到输出之间保留一条直接路径，并用可学习的 $\alpha$ 调节非线性修正。初始化采用 $\alpha = 0.1$，使分支从小幅参与开始，而不是一开始就完全切断。

**它与门控的分工**

$g_i$ 决定第 $i$ 个特征里 **Sin 与 Tanh 如何混合**；$\alpha$ 决定整层的**混合结果如何参与残差输出**。二者调节的位置不同。核心定义没有把 $\alpha$ 限制为正数或限制在 $[0, 1]$。

# 7 手算一次：两个神经元的完整例子

下面取 $m = 2$。所有数值都为便于理解而构造，三个偏置均为零。假设输入与参数如下：

$$\boldsymbol{h} = \begin{bmatrix} 0.5 \\ -0.5 \end{bmatrix}, \quad W_p = \begin{bmatrix} 1 & 1 \\ \pi/2 & -\pi/2 \end{bmatrix}, \quad K = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}, \quad \alpha = 0.1,$$

$$W_a = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \qquad W_g = \begin{bmatrix} \ln 3 & -\ln 3 \\ -\ln 3 & \ln 3 \end{bmatrix}.$$

## 7.1 先算相位与交互

相位为 $\boldsymbol{\theta} = W_p\boldsymbol{h} = [0, \pi/2]^\mathsf{T}$。两项耦合分别为

$$c_1 = \frac{1}{2}(1)\sin(\pi/2 - 0) = 0.5, \qquad c_2 = \frac{1}{2}(-1)\sin(0 - \pi/2) = 0.5.$$

因此 $\boldsymbol{\psi} = [0.5, \pi/2 + 0.5]^\mathsf{T}$。注意第 2 项里，负权重乘上负正弦值，得到的修正仍为正数。

## 7.2 再算两个分支、门控和残差

Tanh 分支输入就是 $\boldsymbol{h}$。门控的加权和为 $[\ln 3, -\ln 3]^\mathsf{T}$，所以门控恰好是 $[0.75, 0.25]^\mathsf{T}$。完整中间结果如下：

| 中间量 | 神经元 1 | 神经元 2 |
|---|---|---|
| 原始相位 $\theta_i$ | 0 | 1.570796 |
| 耦合修正 $c_i$ | 0.500000 | 0.500000 |
| 正弦输出 $p_i$ | 0.479426 | 0.877583 |
| Tanh 输出 $a_i$ | 0.462117 | −0.462117 |
| 门控 $g_i$ | 0.750000 | 0.250000 |
| 混合结果 $f_i$ | 0.475098 | −0.127192 |
| 最终输出 $h_{+,i}$ | 0.544793 | −0.510175 |

例如第 1 个神经元最后两步是：

$$f_1 = 0.75(0.479426) + 0.25(0.462117) \approx 0.475098,$$

$$h_{+,1} = \frac{0.5 + 0.1(0.475098)}{\sqrt{1.01}} \approx 0.544793.$$

> **从这个例子记住什么**
>
> 耦合改变正弦里面的相位；门控混合两个分支；残差再把原输入加回来。隐藏特征可以为负，输出是否要求非负由网络末端的任务接口另行规定。

# 8 从核心层拼成完整网络

## 8.1 一般形式

$$
\begin{aligned}
\boldsymbol{z} &= \mathrm{Encode}(\boldsymbol{x}), & \boldsymbol{z} &\in \mathbb{R}^d, \\
\boldsymbol{h}^{(0)} &= W_{\mathrm{in}}\boldsymbol{z} + \boldsymbol{b}_{\mathrm{in}}, & \boldsymbol{h}^{(0)} &\in \mathbb{R}^m, \\
\boldsymbol{h}^{(\ell+1)} &= \mathcal{Y}_\ell(\boldsymbol{h}^{(\ell)}), & \ell &= 0, \dots, L-1, \\
\boldsymbol{o} &= W_{\mathrm{out}}\boldsymbol{h}^{(L)} + \boldsymbol{b}_{\mathrm{out}}, & \boldsymbol{o} &\in \mathbb{R}^r, \\
\widehat{\boldsymbol{y}} &= T(\boldsymbol{o}). &&
\end{aligned}
\tag{10}
$$

$W_{\mathrm{in}}$ 的形状是 $m \times d$，$W_{\mathrm{out}}$ 的形状是 $r \times m$。中间各层的宽度保持为 $m$。

## 8.2 离散输入接口：Embedding 与分类分数

对于两个整数标签 $(a, b)$，设共享的可训练查找表为 $E \in \mathbb{R}^{p \times d_e}$。先查出两个向量，再按顺序拼接：

$$
\boldsymbol{z} = [E[a]; E[b]] \in \mathbb{R}^{2d_e}.
$$

例如 $p = 97$、$d_e = 128$、$m = 178$、$L = 3$ 时，维度路线是

$$
(a, b) \longrightarrow 256 \longrightarrow 178 \xrightarrow{\text{3 个核心层}} 178 \longrightarrow 97.
$$

末端的 $\boldsymbol{o}$ 是 97 个实数分数（logits）。要选一个类别，可计算 $\arg\max_k o_k$；要表示类别概率，可计算 $e^{o_k} / \sum_j e^{o_j}$。这些是输出接口，不改变核心层。

## 8.3 连续输入接口：时间与非负状态量

对于时间 $\tau \in [\tau_{\min}, \tau_{\max}]$，可以采用线性归一化

$$
z = 2\frac{\tau - \tau_{\min}}{\tau_{\max} - \tau_{\min}} - 1.
$$

若末端有两个原始输出 $o_1, o_2$，并要求它们表示非负状态，可定义

$$
\widehat{n} = \mathrm{softplus}(o_1), \quad \widehat{s} = \mathrm{softplus}(o_2), \qquad \mathrm{softplus}(v) = \ln(1 + e^v).
$$

> **结构层级要分开**
>
> Embedding、时间归一化、Softplus 和分类读出都属于输入或输出接口。YingluoLayer 内部仍采用同一套相位、耦合、门控和残差公式。这里的 Softplus 是输出映射，不是把监督目标改成对数。

# 9 批量前向传播：与张量维度对应

程序通常把一个样本放在一行。为避免与偏置 $\boldsymbol{b}$ 混淆，下面用 $b$ 表示批量大小。输入矩阵为 $H \in \mathbb{R}^{b\times m}$。

## 9.1 一次计算整批样本

设 $\mathbf{1}_b$ 是长度为 $b$ 的全 1 列向量，$\mathsf{M} = \mathbf{1}_{m\times m} - I_m$ 是对角线为零的掩码。定义有效耦合矩阵 $K_{\text{eff}} = K \odot \mathsf{M}$。

$$
\begin{aligned}
\Theta &= HW_p^{\mathsf{T}} + \mathbf{1}_b \boldsymbol{b}_p^{\mathsf{T}}, \\
U &= \sin\Theta, \qquad V = \cos\Theta, \\
C &= \frac{V \odot (UK_{\text{eff}}^{\mathsf{T}}) - U \odot (VK_{\text{eff}}^{\mathsf{T}})}{m}, \\
P &= \sin(\Theta + C), \\
A &= \tanh(HW_a^{\mathsf{T}} + \mathbf{1}_b \boldsymbol{b}_a^{\mathsf{T}}), \\
G &= \operatorname{sigmoid}(HW_g^{\mathsf{T}} + \mathbf{1}_b \boldsymbol{b}_g^{\mathsf{T}}), \\
F &= G \odot P + (\mathbf{1}_{b\times m} - G) \odot A, \\
H_+ &= \frac{H + \alpha F}{\sqrt{1+\alpha^2}}.
\end{aligned}
\tag{11}
$$

这些中间矩阵的形状全部为 $b \times m$。$\mathbf{1}_b \boldsymbol{b}_p^{\mathsf{T}}$ 表示把同一条偏置复制到每个样本；程序中通常通过广播完成。

## 9.2 转置为什么出现

单样本列向量写法是 $W_p\boldsymbol{h}$。把样本改成行向量后，同一个运算写成 $\boldsymbol{h}^{\mathsf{T}}W_p^{\mathsf{T}}$；堆叠多行就得到 $HW_p^{\mathsf{T}}$。耦合矩阵的转置同理。

| 运算 | 形状检查 | 输出形状 |
|---|---|---|
| $HW_p^{\mathsf{T}}$ | $(b\times m)(m\times m)$ | $b\times m$ |
| $UK_{\text{eff}}^{\mathsf{T}}$ | $(b\times m)(m\times m)$ | $b\times m$ |
| $G \odot P$ | 两者均为 $b\times m$ | $b\times m$ |
| $H + \alpha F$ | 同形状相加 | $b\times m$ |

> **批量不会引入样本间的耦合**
>
> 第 $r$ 行的相位修正只由第 $r$ 行的相位计算；$K$ 混合的是同一样本内部的神经元维度，不是不同样本。当前核心层没有跨样本的统计操作。

# 10 参数初始化与参数量

## 10.1 当前核心层的初始化口径

| 参数 | 初始设置 | 直观含义 |
|---|---|---|
| $W_p, W_a, W_g$ | Xavier 均匀初始化 | 三组矩阵分别随机生成 |
| $\boldsymbol{b}_p, \boldsymbol{b}_a, \boldsymbol{b}_g$ | 全零 | 起点不加额外偏置 |
| $K$ | 全零 | 起点的相位修正为零 |
| $\alpha$ | 0.1 | 非线性分支从小幅参与开始 |
| 有效耦合对角线 | 始终为零 | 通过固定掩码屏蔽 |

这里对三组方阵采用增益为 1 的 Xavier 均匀初始化，即

$$W_{ij} \sim \mathcal{U}\left(-\sqrt{\frac{6}{m+m}}, \sqrt{\frac{6}{m+m}}\right) = \mathcal{U}\left(-\sqrt{\frac{3}{m}}, \sqrt{\frac{3}{m}}\right).$$

输入层、输出层和 Embedding 的初始化属于外围接口配置。初始化只是参数的起点，训练后参数通常会改变。

## 10.2 一层包含多少参数

三条线性分支合计 $3m^2 + 3m$ 个参数；完整存储的耦合矩阵有 $m^2$ 个参数；另有一个 $\alpha$，所以

$$\boxed{P_{\text{layer}} = 4m^2 + 3m + 1.} \tag{12}$$

若只数直接参与前向计算的参数元素，耦合矩阵剩 $m(m-1)$ 项，因此 $P_{\text{layer,eff}} = 4m^2 + 2m + 1$。常见的参数计数仍会包含被屏蔽的 $m$ 个对角元素；掩码本身不是可训练参数。

## 10.3 完整网络的参数量

编码输出维度为 $d$、输出维度为 $r$ 时，不含编码器的总量为

$$\boxed{P = (d+1)m + L(4m^2 + 3m + 1) + (m+1)r.} \tag{13}$$

若采用 $p \times d_e$ 的 Embedding 表，还需加上 $pd_e$。

| 结构配置 | 完整存储计数 | 去除屏蔽对角线后 |
|---|---|---|
| $d = 1, m = 98, L = 3, r = 2$ | 116,527 | 116,233 |
| $d = 256, m = 178, L = 3, r = 97$，另加 $97 \times 128$ Embedding | 457,338 | 456,804 |

# 11 拓展阅读：梯度怎样穿过核心层

这一节只解释局部梯度。设整个任务的损失为 $\mathcal{L}$，从后续网络传来的梯度是 $\boldsymbol{u} = \partial\mathcal{L}/\partial\boldsymbol{h}_+$。

## 11.1 从残差输出进入混合特征

$$\boxed{\boldsymbol{q} = \frac{\partial\mathcal{L}}{\partial\boldsymbol{f}} = \frac{\alpha}{\sqrt{1+\alpha^2}}\boldsymbol{u}.}$$

之后沿两条分支分别传递：

$$\frac{\partial\mathcal{L}}{\partial\boldsymbol{p}} = \boldsymbol{q}\odot\boldsymbol{g}, \qquad \frac{\partial\mathcal{L}}{\partial\boldsymbol{a}} = \boldsymbol{q}\odot(\mathbf{1}-\boldsymbol{g}).$$

设门控的线性输入为 $\boldsymbol{v}_g = W_g\boldsymbol{h} + \boldsymbol{b}_g$，则

$$\frac{\partial\mathcal{L}}{\partial\boldsymbol{v}_g} = \boldsymbol{q}\odot(\boldsymbol{p}-\boldsymbol{a})\odot\boldsymbol{g}\odot(\mathbf{1}-\boldsymbol{g}).$$

这表明门控的梯度同时取决于两个分支的差别、当前门控值，以及后面传来的任务误差信号。

## 11.2 相位耦合矩阵怎样得到梯度

先穿过外层正弦，记

$$\boldsymbol{\delta} = \frac{\partial\mathcal{L}}{\partial\boldsymbol{\psi}} = \boldsymbol{q}\odot\boldsymbol{g}\odot\cos\boldsymbol{\psi}.$$

对一条有效连接 $i \neq j$，有

$$\boxed{\frac{\partial\mathcal{L}}{\partial K_{ij}} = \frac{\delta_i}{m}\sin(\theta_j-\theta_i).} \tag{14}$$

因此，$K=0$ **并不会自动让** $K$ **的梯度为零**。只要上游梯度和相位差提供非零信号，零初始化的耦合权重仍可改变。批量训练时，再按照损失的求和或平均方式汇总各样本贡献。

## 11.3 为什么保留残差路径

记 $J_f = \partial\boldsymbol{f}/\partial\boldsymbol{h}$，则当前层对输入的雅可比矩阵为

$$\boxed{J_{\mathcal{Y}} = \frac{I_m + \alpha J_f}{\sqrt{1+\alpha^2}}.} \tag{15}$$

其中 $I_m$ 来自直接路径。$\alpha$ 很小时，这条路径接近恒等传播；但完整梯度仍取决于 $J_f$，不能仅凭残差形式就断言梯度尺度一定稳定。

> **为什么不把 $\alpha$ 也初始化为零**
>
> 若 $\alpha=0$，该层输出恰好等于输入，但上面的 $\boldsymbol{q}$ 也为零，分支内部参数在这次反向传播中得不到来自该分支的梯度。取 0.1 是让直接路径和分支训练同时保留的起点设置。

# 12 读公式时的几个关键细节

## 12.1 这是一次前馈变换，而不是跨样本记忆

对当前输入生成 $\boldsymbol{\theta}$，计算一次 $\boldsymbol{c}$，再输出 $\boldsymbol{h}_+$。每次前向传播都从当前输入重新计算中间量。数学定义中没有把上一次调用的相位保存到下一次调用。

## 12.2 相位平移对耦合和输出的影响不同

把所有相位加上同一个实数 $\delta$，相位差不变：

$$(\theta_j + \delta) - (\theta_i + \delta) = \theta_j - \theta_i.$$

所以 $\boldsymbol{c}$ 不变，但 $\sin(\boldsymbol{\theta} + \boldsymbol{c} + \delta\mathbf{1})$ 一般会变。**耦合项的共同平移不变性，不等于整个正弦分支的输出不变**。

## 12.3 关闭一个机制后，公式还剩什么

当 $K = 0$ 时，核心层的混合特征为

$$\boldsymbol{f} = \boldsymbol{g} \odot \sin(W_p\boldsymbol{h} + \boldsymbol{b}_p) + (\mathbf{1} - \boldsymbol{g}) \odot \tanh(W_a\boldsymbol{h} + \boldsymbol{b}_a).$$

它仍然包含两条非线性分支、门控和残差。只有进一步让门控接近零，才会接近单独的 Tanh 分支；让门控接近一，则接近正弦分支。若 $\alpha = 0$，整个核心层直接变为恒等映射。

## 12.4 有界的是分支特征，不是任意输入下的完整输出

因为 $|p_i| \le 1$、$|a_i| < 1$，且 $0 < g_i < 1$，所以

$$|f_i| \le 1, \qquad |h_{+,i}| \le \frac{|h_i| + |\alpha|}{\sqrt{1 + \alpha^2}}.$$

后一个上界仍然依赖输入 $h_i$。这说明非线性修正的幅度受到限制，但没有把整张网络的输出固定限制在 $[-1, 1]$。

## 12.5 门控、耦合、损失：分别属于哪一层概念

$K$ 决定相位如何交互；$\boldsymbol{g}$ 决定两个分支如何混合；$\alpha$ 决定混合特征如何加入残差。损失函数则放在完整网络输出之后，告诉优化过程“哪些输出更符合目标”。

> **最简洁的结构描述**
>
> **YingluoNet v1.1 是把相位差交互、Sin/Tanh 门控混合与缩放残差组合起来的前馈网络。**
> 理解它时，先分清三种作用发生的位置，再讨论具体的输入接口与输出接口。

# A 一页速查：核心公式与计算顺序

**单个样本 · 列向量约定**

输入 $\boldsymbol{h} \in \mathbb{R}^m$；$W_p, W_a, W_g, K \in \mathbb{R}^{m\times m}$；三个偏置均为 $m$ 维；$\alpha \in \mathbb{R}$；有效耦合矩阵满足 $K_{ii} = 0$。

1. 原始相位 $\quad \boldsymbol{\theta} = W_p\boldsymbol{h} + \boldsymbol{b}_p,$
2. 相位修正 $\quad c_i = \dfrac{1}{m}\sum_j K_{ij}\sin(\theta_j - \theta_i),$
3. 正弦分支 $\quad \boldsymbol{p} = \sin(\boldsymbol{\theta} + \boldsymbol{c}),$
4. Tanh 分支 $\quad \boldsymbol{a} = \tanh(W_a\boldsymbol{h} + \boldsymbol{b}_a),$
5. 门控比例 $\quad \boldsymbol{g} = \mathrm{sigmoid}(W_g\boldsymbol{h} + \boldsymbol{b}_g),$
6. 特征混合 $\quad \boldsymbol{f} = \boldsymbol{g}\odot\boldsymbol{p} + (\mathbf{1}-\boldsymbol{g})\odot\boldsymbol{a},$
7. 残差输出 $\quad \boxed{\boldsymbol{h}_+ = \dfrac{\boldsymbol{h} + \alpha\boldsymbol{f}}{\sqrt{1+\alpha^2}}.}$

## 耦合的等价矩阵公式

$$\boxed{\boldsymbol{c} = \frac{\cos\boldsymbol{\theta}\odot(K\sin\boldsymbol{\theta}) - \sin\boldsymbol{\theta}\odot(K\cos\boldsymbol{\theta})}{m}.}$$

## 完整网络的连接关系

$$\boldsymbol{x} \xrightarrow{\text{Encode}} \boldsymbol{z} \xrightarrow{\text{Linear}} \boldsymbol{h}^{(0)} \xrightarrow{\mathcal{Y}_0} \cdots \xrightarrow{\mathcal{Y}_{L-1}} \boldsymbol{h}^{(L)} \xrightarrow{\text{Linear}} \boldsymbol{o} \xrightarrow{T} \widehat{\boldsymbol{y}}.$$

| 机制 | 一句话记忆 |
|---|---|
| 相位耦合 $K$ | 先看相位差，再改正弦里面的相位 |
| 门控 $\boldsymbol{g}$ | 对每个输入、每个特征计算 Sin/Tanh 混合比例 |
| 残差 $\alpha$ | 保留输入，同时加入经过缩放的非线性修正 |

**源文件编译** 本说明书为 UTF-8 编码的独立 LaTeX 文件，使用 `ctexart`、`amsmath`、`TikZ` 等宏包；所有图均为矢量结构图。使用 XeLaTeX 编译两次即可更新目录与页码。